

2016311924 통계학과 양지연



01_{AutoEncoder} 기본 구성

03 Application

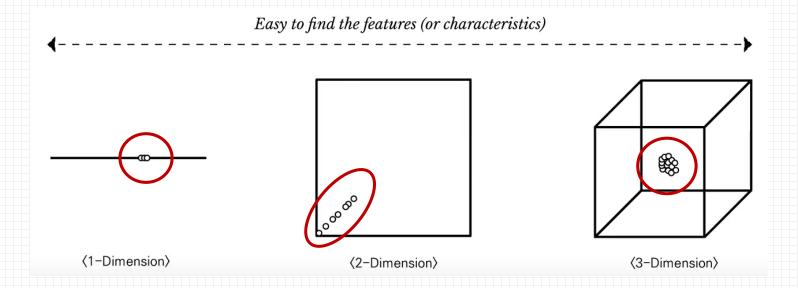
02 구체적인 모델 및 활용 방식

04 한계 및 발접 방향성

차원 축소를 하는 이유: 자원이 저주

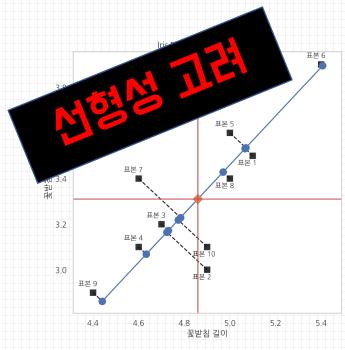
(Curse of Dimensionality)

- → 고차원 공간의 데이터를 분석하거나 측정할 때 저차원 공간에서는 나타나지 않았던 여러 문제들이 발생하는 것
- → 머신 러닝에서는 일반적으로 차원이 증가할 경우 기하급수적인 데이터가 요구되는 현상

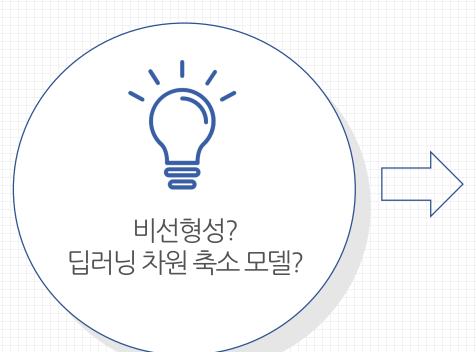


차염의 저주

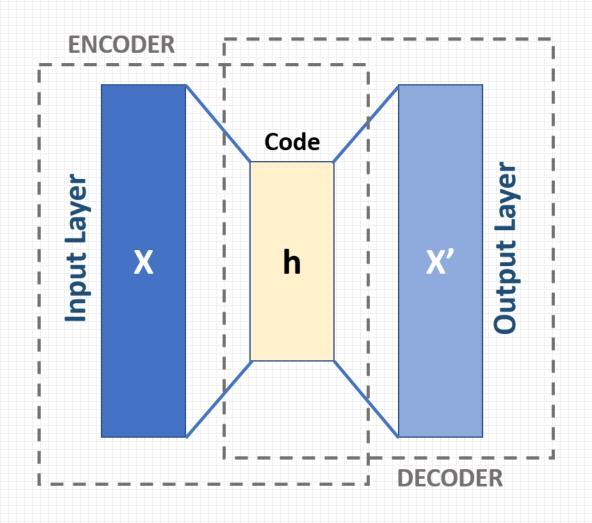
(Curse of Dimensionality)







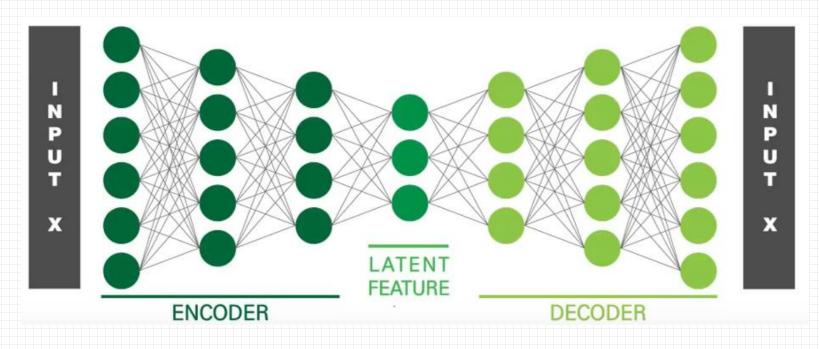




- →data-specific 합니다
- →손실이 있습니다.
- →예제 데이터로부터 자동적으로 학습합니다.

Keyword

Unsupervised Learning (비지도 학습) Manifold Learning (차원축소) Generative model (생성 모델)



Keyword

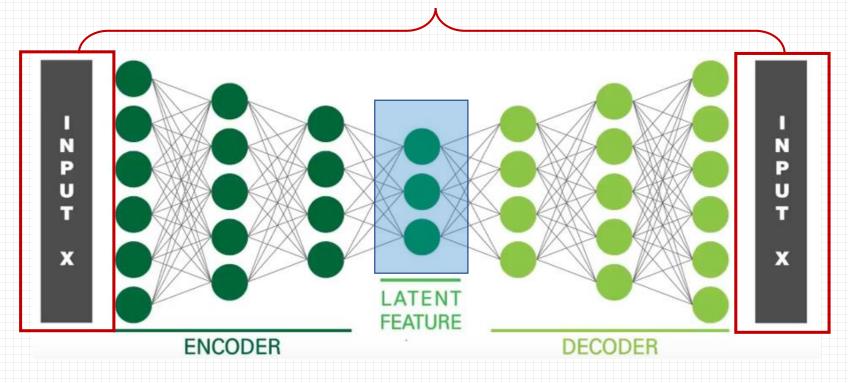
Unsupervised Learning (비지도 학습) Manifold Learning

> Generative model (생성 모델)

(차원축소)

- → 인코더(encoder): 입력을 내부 표현으로 변환한다.
- → 디코더(decoder): 내부 표현을 출력으로 변환한다.
- → Latent Feature: 신경망 내부에서 추출된 특징적 값들.

Unsupervised Learning에 Supervised Learning방식을 사용



Keyword

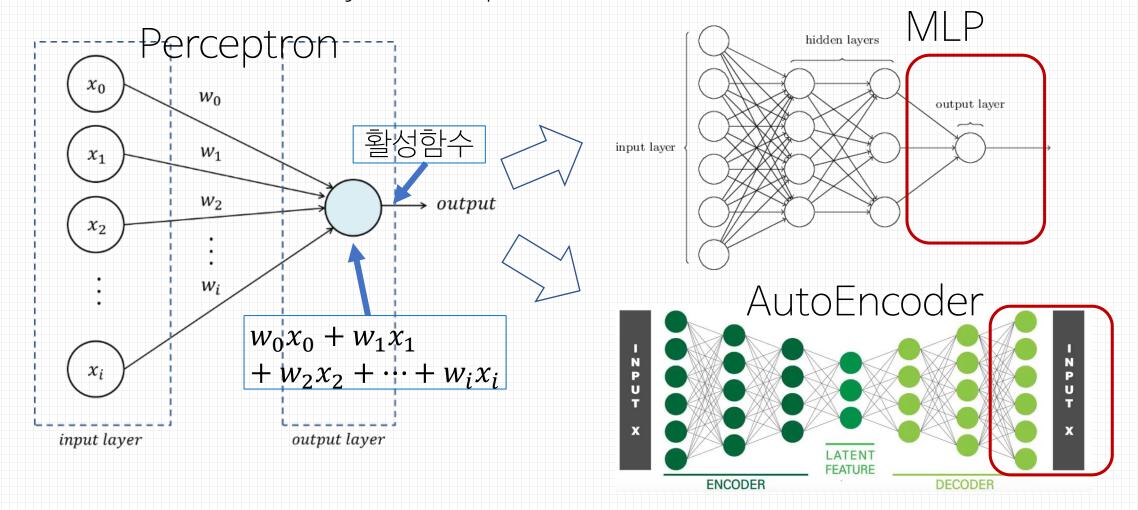
Unsupervised Learning (비지도 학습)

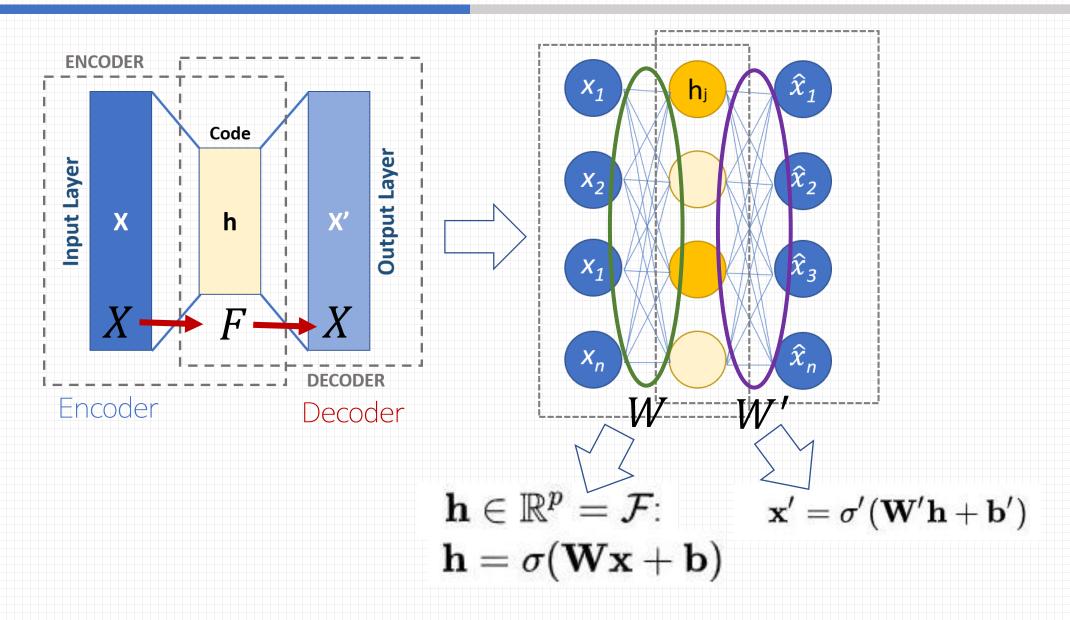
> Manifold Learning (차원축소)

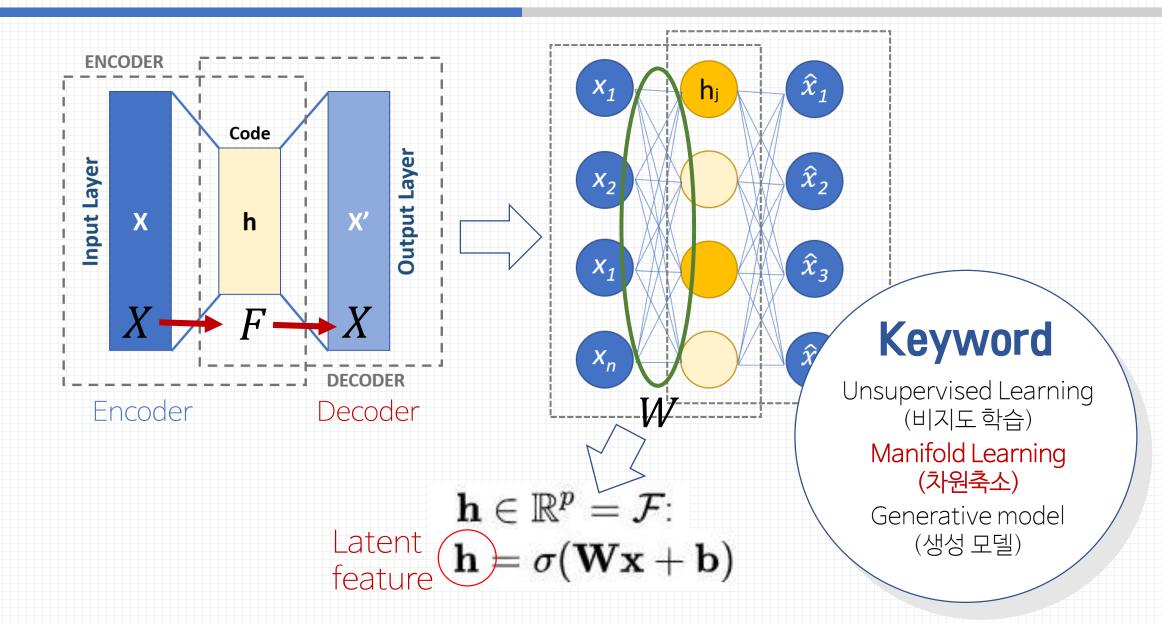
Generative model (생성 모델)

- → 인코더(encoder): 입력을 내부 표현으로 변환한다.
- → 디코더(decoder): 내부 표현을 출력으로 변환한다.
- → Latent Feature: 신경망 내부에서 추출된 특징적 값들.

입력과 출력층의 뉴런 수가 동일하다는 것만 제외하면 일반적인 MLP(Multi-layer Perceptron)과 동일한 구조







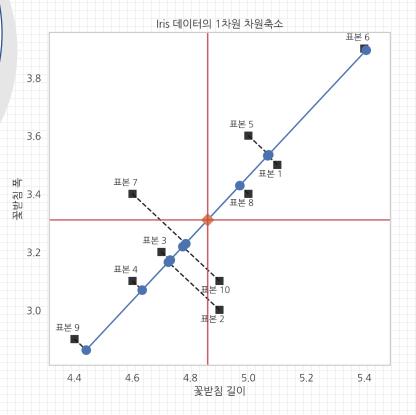
Keyword

Unsupervised Learning (비지도 학습)

> Manifold Learning (차원축소)

> Generative model (생성 모델)

PCA(선형 차원 축소 방법)



저차원의 경우 시각적으로 차원 축소의 방향과 정보를 손쉽게 직관적으로 발견 가능

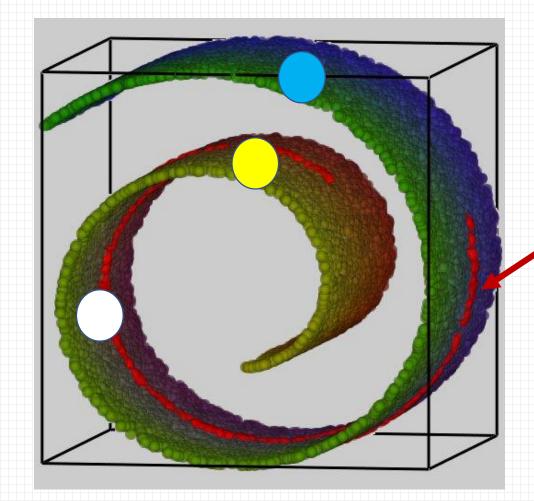
2차워 → 1차워

Keyword

Unsupervised Learning (비지도 학습)

> Manifold Learning (차원축소)

> Generative model (생성 모델)



고차원 데이터를 저차원으로 나타낼 수 있 는 핵심적인 정보

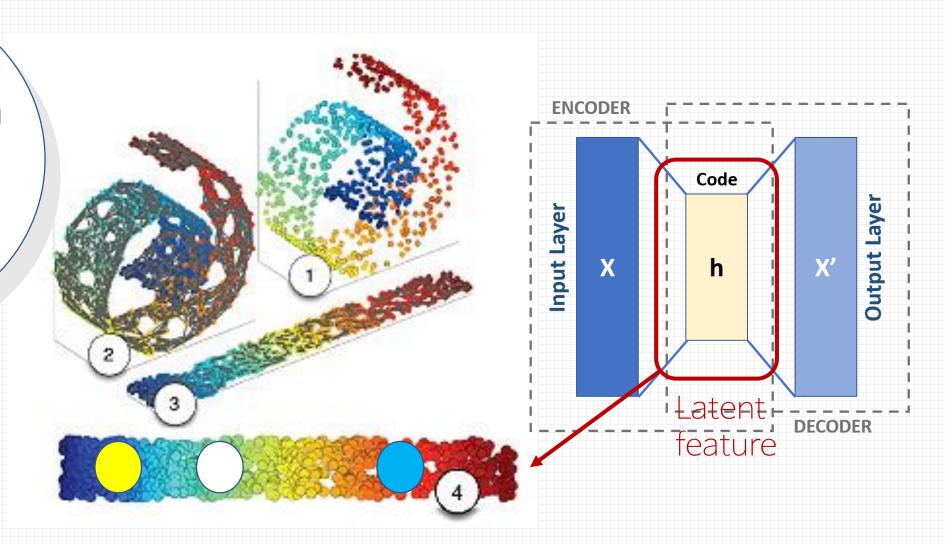
Manifold

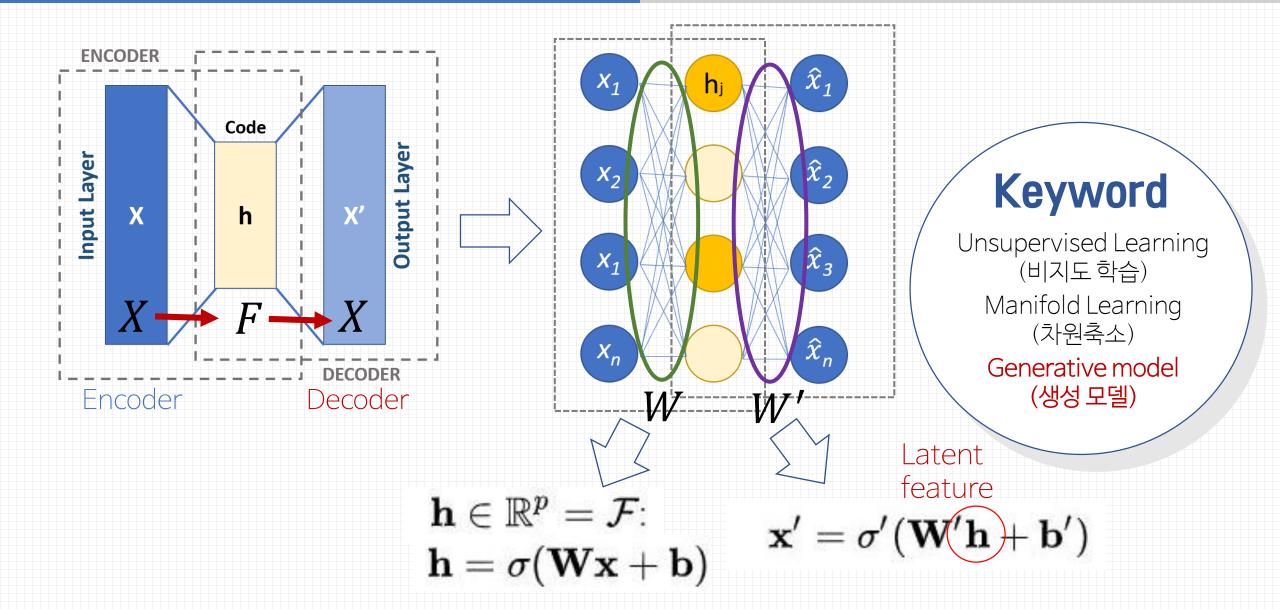
Keyword

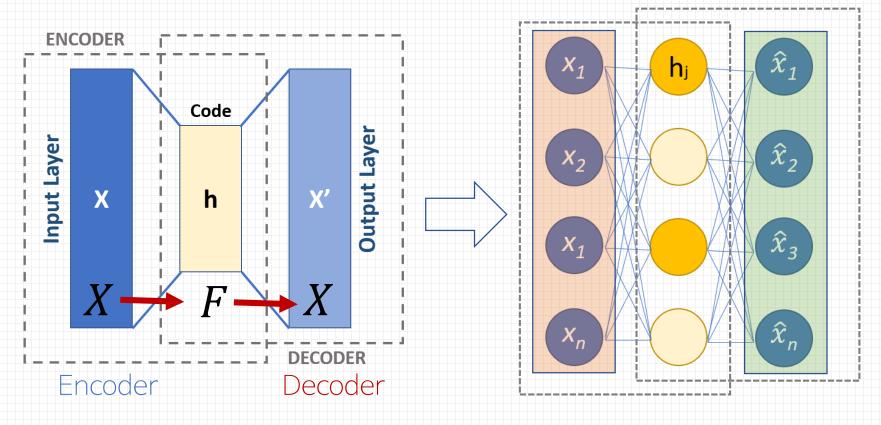
Unsupervised Learning (비지도 학습)

> Manifold Learning (차원축소)

> Generative model (생성 모델)





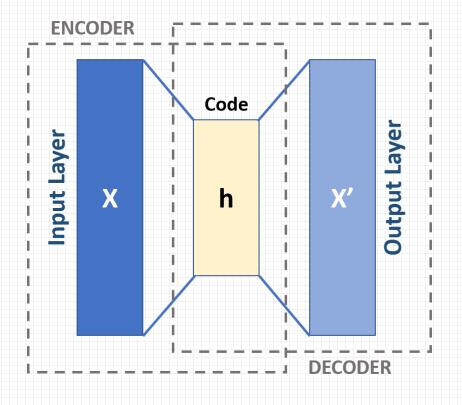


$$\mathcal{L}(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\|^2 = \|\mathbf{x} - \sigma'(\mathbf{W}'(\sigma(\mathbf{W}\mathbf{x} + \mathbf{b})) + \mathbf{b}')\|^2$$

정답인 X 값들과 압축 후 다시 복원해낸 출력 X 값들 사이의 차이

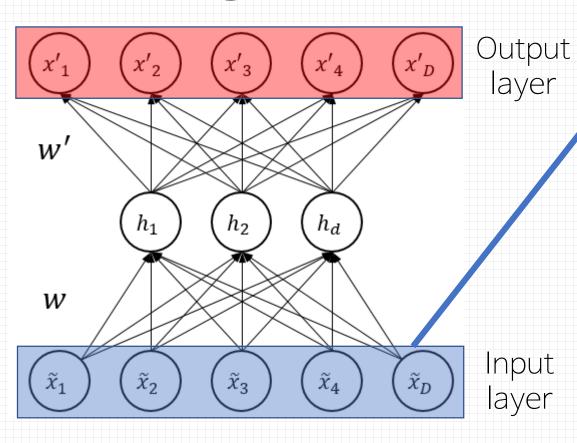
AutoEncoder 모델 종류

- → Sparse AutoEncoder
- → Denoising AutoEncoder
- → Contractive AutoEncoder
- → Variational AutoEncoder



02 구체적인 모델 및 활용 방식

Denoising AutoEncoder



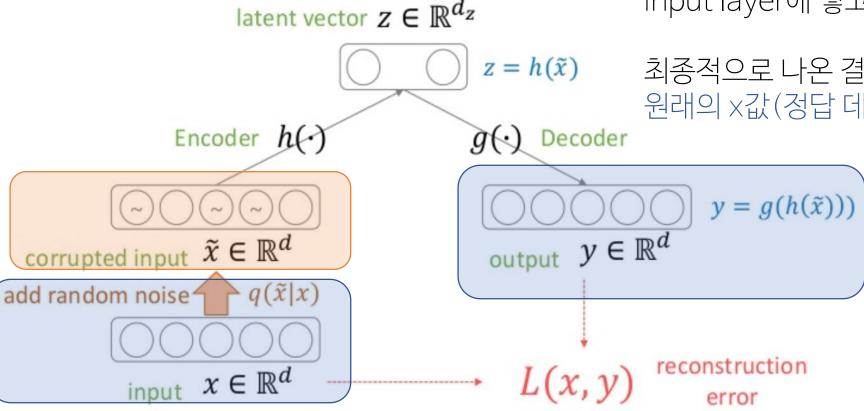


AutoEncoder에 차위에 가이 하는 원래의 Noise? 에

→ Nation Natio

02 구체적인 모델 및 활용 방식

Denoising AutoEncoder

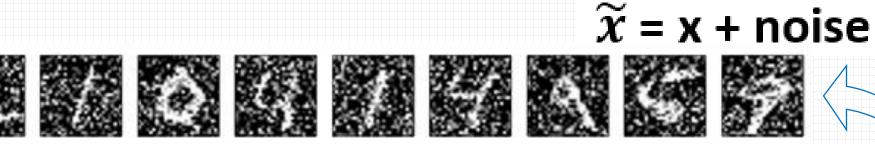


변형된 x 값(원래의 x값 데이터에 노이즈 추가)을 input layer에 넣고 모델 학습

최종적으로 나온 결과값은 변형된 x 값이 아닌 원래의 x값(정답 데이터)와 비교해서 학습

02 구체적인 모델 종류 및 활용 방식

Denoising AutoEncoder





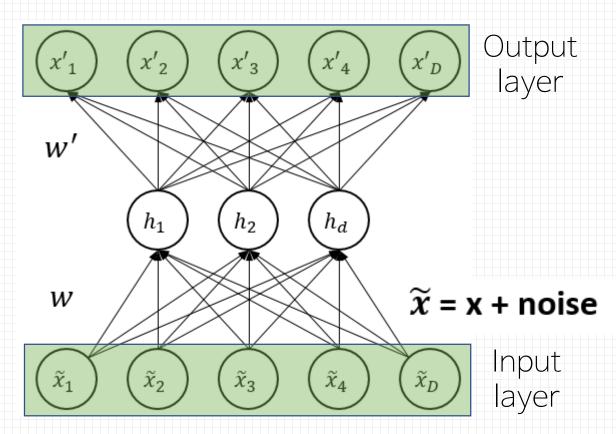


Noise 추가



- 이번엔 좀 더 난이도 있는 문제를 줄게! 여기서 노이즈를 제거하고 원본을 복구 시켜봐!
- → 잡음을 제거하기 위한 노력이 추가
- →이 과정에서 더 정확한 Manifold를 찾아낼 수 있다!

Denoising AutoEncoder



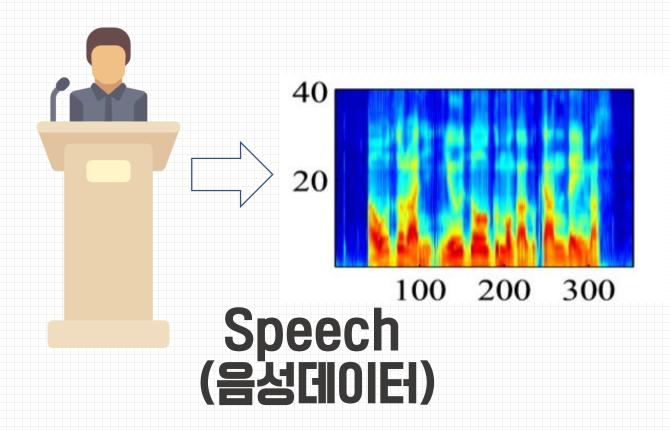
AutoEncoder

- → data-specific 하다
- → Train data에 대해서는 정확하게 정보를 압축하고 복원하는 것이 가능
- →But, 새로운 데이터에 대해서는 취약

Denoising AutoEncoder

- → 원본데이터에서 노이즈를 추가한 데이터 학습
- → Local한 특징을 뽑아내는 AutoEncoder에 비해 조금은 Global한 특징을 뽑아낼 수 있음.





Speech Enhancement 3計川号표

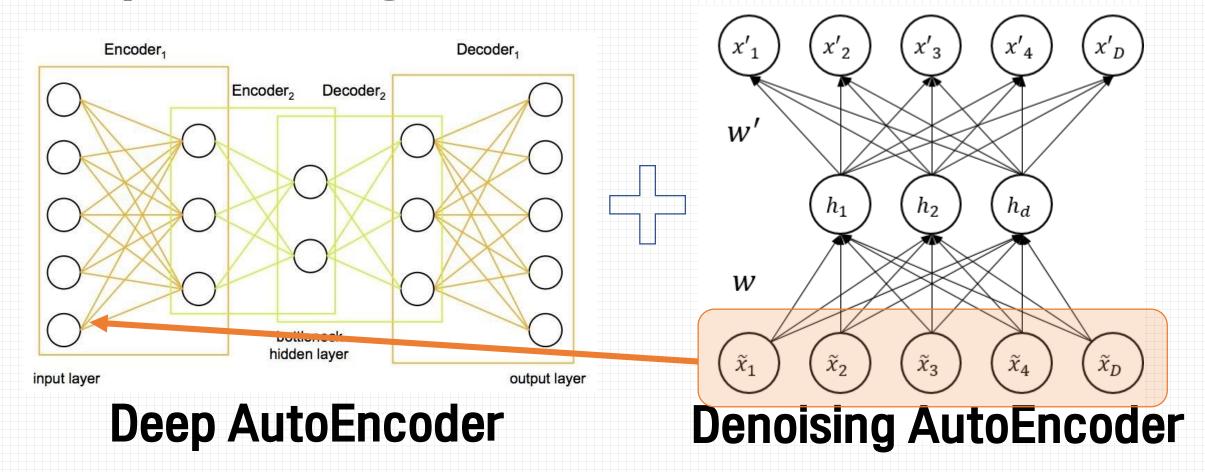
Noise Reduction (소음 축소)

Speech Distortion (연설 왜곡)

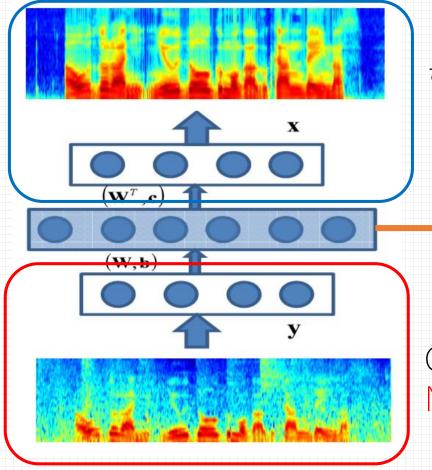
Perceptual Evaluation of Speech Quality (음성 품질 평가)



Deep Denoising AutoEncoder







학습을 통해 나온 결과값은 원래의 Clean한 데이터 (X로 표현)와 비교해서 학습

원하는 Depth(깊이)만큼 은닉층(hidden layer) 늘여서 모델 구성

Clean한 Speech 음성 데이터에 noise를 추가한 Noise data(Y로 표현) input에 삽입

03 Aplication

Speech Enhancement Based on Deep Denoising Autoencoder(DDAE)

Speech Enhancement 3개지 목표

> Noise Reduction (소음 축소)

Speech Distortion (연설 왜곡)

Perceptual Evaluation of Speech Quality (음성 품질 평가)

Reduct
$$\triangleq \frac{1}{N*d} \sum_{i=1}^{N} |\hat{\mathbf{x}}_i - \mathbf{y}_i|$$
 Noise data에서 노이즈를 얼마나 제거해냈는지 측정 \rightarrow 클수록 Good

Speech의 Quality 측정하는 값 주관적인 정보를 객관적으로 측정 (복잡한 방식이므로 생략)



Table 4: Performance regarding to hidden layer size

hidsize	100	300	500
Reduct (dB)	1.93	1.93	1.93
Dist (dB)	0.47	0.44	0.43
PESQ	3.33	3.44	3.52

Latent variable의 사이즈 값을 100 / 300 / 500으로 두고 각각 어떤 모델이 더 좋은 결과를 보였는지를 비교

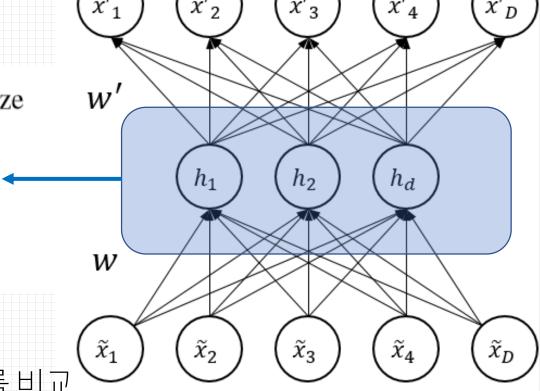




Table 5: Effect of depth in DAE

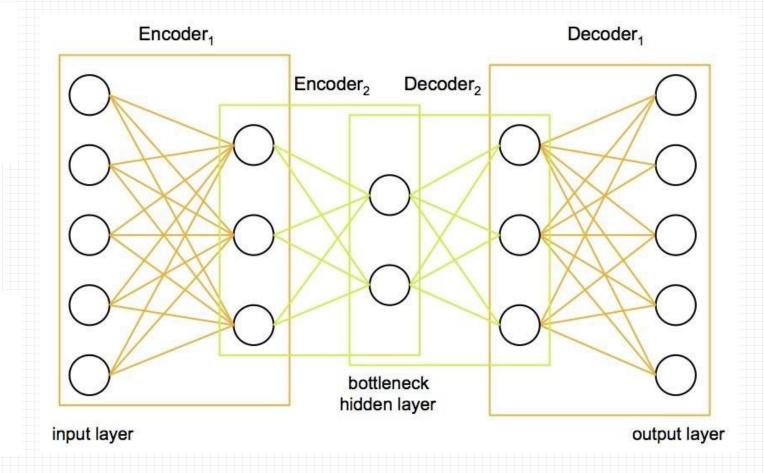
hidsize*layer	100*1	100*2	100*3
Reduct (dB)	1.93	1.93	1.93
Dist (dB)	0.47	0.44	0.43
PESQ	3.33	3.39	3.39

Table 6: Effect of depth in DAE

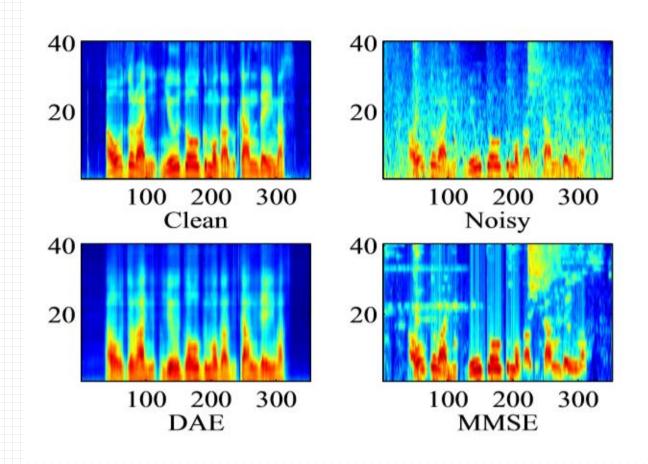
hidsize*layer	300*1	300*2	300*3
Reduct (dB)	1.93	1.92	1.92
Dist (dB)	0.44	0.40	0.40
PESQ	3.44	3.52	3.61

Table 7: Effect of depth in DAE

hidsize*layer	500*1	500*2	500*3
Reduct (dB)	1.93	1.91	1.92
Dist (dB)	0.43	0.40	0.42
PESQ	3.52	3.61	3.52

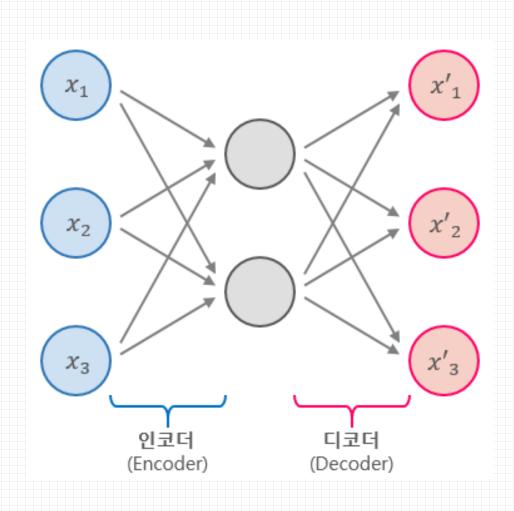






결과적으로 보면 기존에 사용되던 MMSE 모델보다 Deep Denoising AutoEncoder가 원래의 Clean한 데이터를 잘 복원해 내는 것을 볼 수 있습니다.

04 학계 및 발전 방향성



AutoEncoder는 데이터 압축에 좋을까요?

일반적으로는 그렇지 않습니다.

사진 압축에서 AutoEncoder의 성능을 높이는 방법은 사진을 매우 특정한 유형으로 제한하는 것.

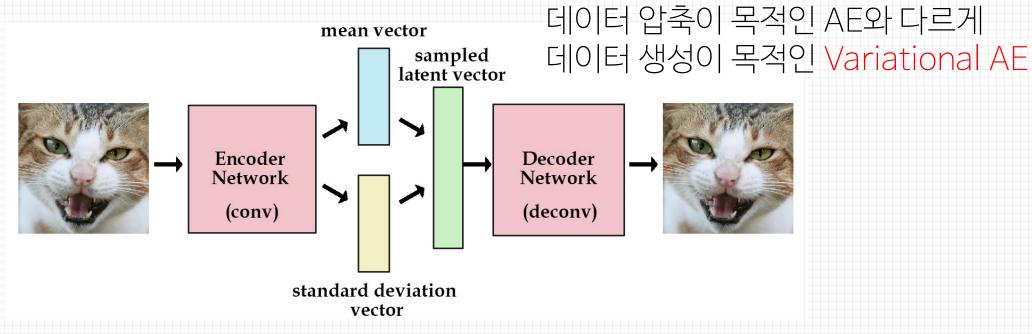
AutoEncoder가 data-specific 하다는 점 때문에 실제 데이터 압축 문제에 적용하기에 비실용적입니다.

따라서 AutoEncoder는 훈련된 것과 비슷한 데이터에 서만 사용될 수 있고, 일반적인 데이터에 대해 사용하기 위해서는 많은 훈련 데이터가 필요합니다.

04 한계 및 발전 가능성



Variational AutoEncoder(VAE)



Generation(생성) 부분인 Decoder부분이 기존의 AE보다 훨씬 잘 학습

- → Conditional Variational AE(CVAE)
- → Adversarial AutoEncoder (AAE)







참고 논문:

- 1. Why Does Unsupervised Pre-training Help Deep Learning?
- -Journal of Machine Learning Research 11 (2010) 625-660 Submitted 8/09; Published 2/10
- 2. Speech Enhancement Based on Deep Denoising Autoencoder
- -Copyright © 2013 ISCA 25-29 August 2013, Lyon, France

참고 사이트:

- 1. https://www.slideshare.net/NaverEngineering/ss-96581209
- 2. https://sacko.tistory.com/10
- 3. https://www.youtube.com/watch?v=YxtzQbe2UaE&list=PLCsGBQ3i2iIXVJoQf4Lln-szoMae9H8aq&index=11
- 4. https://en.wikipedia.org/wiki/Autoencoder
- 5. https://excelsior-cjh.tistory.com/187